

Báo cáo LabX: Tìm hiểu về Text-To-Speech

Sinh viên: Nguyễn Thùy Trang

Mã sinh viên: 22000128

Tháng 12 năm 2025

Mục lục

1	Giới thiệu	2
2	Bài toán Text-To-Speech	2
2.1	Tổng quan bài toán	2
2.2	Lịch sử hình thành	2
2.3	Ứng dụng của bài toán	2
3	Các hướng tiếp cận chính	3
3.1	Level 1: Hệ thống dựa trên luật và ghép nối (Rule-based & Concatenative)	3
3.2	Level 2: Mô hình Deep Learning (Neural TTS)	3
3.3	Level 3: Few-shot và Voice Cloning (Generative Models)	4
4	So sánh tổng hợp các hướng tiếp cận	4
5	Một số hướng nghiên cứu pipeline tối ưu hóa	6
5.1	Tối ưu hóa Pipeline và Triển khai (Optimization & Deployment)	6
5.2	Các hướng nghiên cứu tiềm năng	6
6	Kết luận	6
7	Tài liệu tham khảo	7

1 Giới thiệu

Báo cáo này trình bày tổng quan về bài toán Text-To-Speech (TTS) trong trí tuệ nhân tạo, tập trung vào khái niệm, vai trò và lịch sử phát triển của các hệ thống chuyển văn bản thành giọng nói. Text-To-Speech là công nghệ cho phép máy tính chuyển đổi chuỗi ký tự đầu vào thành tín hiệu âm thanh giọng nói, được ứng dụng rộng rãi trong trợ lý ảo, hệ thống tổng đài, đọc sách nói và hỗ trợ tiếp cận thông tin cho người khiếm thị.

Về lịch sử, TTS ban đầu được xây dựng chủ yếu theo hướng dựa trên luật với các bộ quy tắc ngữ âm và ngữ điệu thủ công, cho phép hệ thống chạy nhanh, ít tốn tài nguyên nhưng giọng nói còn cứng và thiếu tự nhiên. Sự phát triển của deep learning đã dẫn tới các mô hình neural end-to-end như WaveNet, Tacotron hay FastSpeech, giúp cải thiện rõ rệt độ tự nhiên và khả năng thể hiện cảm xúc trong giọng nói nhưng đi kèm yêu cầu dữ liệu và tài nguyên tính toán lớn hơn.

Trong bối cảnh đó, báo cáo này sẽ lần lượt giới thiệu bức tranh tổng quan nghiên cứu TTS hiện nay, phân tích ba hướng tiếp cận chính (Level 1 – hệ thống dựa trên luật, Level 2 – mô hình deep learning, Level 3 – few-shot/voice cloning), so sánh ưu nhược điểm và các trường hợp sử dụng phù hợp, đồng thời trình bày một số pipeline tiêu biểu nhằm giảm thiểu nhược điểm và phát huy ưu điểm của từng hướng. Qua đó, báo cáo hướng tới giúp người đọc có được cái nhìn hệ thống về TTS, làm nền tảng cho việc tìm hiểu sâu hơn hoặc triển khai các mô hình TTS trong các bài toán ứng dụng sau này.

2 Bài toán Text-To-Speech

2.1 Tổng quan bài toán

Text-to-Speech (TTS) là bài toán chuyển đổi đầu vào dạng văn bản thành tín hiệu âm thanh giọng nói sao cho người nghe cảm nhận được nội dung, ngữ điệu và, ngày càng nhiều hơn, cả cảm xúc của người nói. Mục tiêu tối thượng của hệ thống TTS là cực đại hóa hai yếu tố:

- Độ dễ hiểu (Intelligibility): Người nghe có thể nhận diện chính xác nội dung văn bản được truyền tải.
- Độ tự nhiên (Naturalness): Giọng nói tạo ra phải mang các đặc trưng của con người như ngữ điệu (prosody), nhịp điệu (rhythm), trọng âm và cảm xúc, tránh cảm giác máy móc hay ngắt quãng.

Về mặt toán học, nếu xem văn bản đầu vào là chuỗi X và tín hiệu âm thanh đầu ra là Y , bài toán TTS là việc tìm mô hình để ước lượng xác suất có điều kiện $P(Y|X)$. Các hệ thống hiện đại không chỉ dừng lại ở việc đọc đúng từ, mà còn hướng tới khả năng tạo giọng mới chưa từng thấy trong huấn luyện và chuyển đổi phong cách biểu cảm.

2.2 Lịch sử hình thành

Về lịch sử, các hệ thống TTS đầu tiên (từ khoảng thập niên 1970–1990) chủ yếu dựa trên luật và mô hình âm học đơn giản (formant/concatenative), dùng tập quy tắc ngữ âm – ngữ điệu thủ công cho từng ngôn ngữ; ưu điểm là chạy rất nhanh, ít tốn tài nguyên và dễ mở rộng sang nhiều ngôn ngữ, nhưng giọng nói thường “robot”, thiếu tự nhiên. Từ khoảng 2016 trở lại đây, với sự xuất hiện của các mô hình deep learning như WaveNet, Tacotron, FastSpeech, TTS chuyển sang hướng neural end-to-end: mô hình học trực tiếp từ cặp văn bản–giọng nói quy mô lớn, cho ra chất lượng tự nhiên gần giọng người thật, hỗ trợ cảm xúc và đa phong cách, nhưng đòi hỏi nhiều dữ liệu và tài nguyên tính toán hơn.

Giai đoạn gần đây, nghiên cứu tập trung mạnh vào TTS đa ngôn ngữ, TTS cá nhân hóa và học ít mẫu: người dùng chỉ cần ghi vài chục giây tới vài phút là hệ thống đã có thể tạo giọng nói mang đặc trưng riêng, hoặc thậm chí few-shot/zero-shot voice cloning chỉ với vài giây tiếng nói. Xu hướng mới còn bao gồm dùng mô hình lớn (large neural / codec / diffusion models) để tổng hợp giọng có cảm xúc, linh hoạt phong cách, đồng thời tối ưu hóa để chạy thời gian thực trên thiết bị biên (edge) thông qua mô hình nhẹ, nén, và distillation.

2.3 Ứng dụng của bài toán

Với sự phát triển về chất lượng tổng hợp và khả năng triển khai thực tế, công nghệ Text-to-Speech (TTS) hiện được ứng dụng rộng rãi trong nhiều lĩnh vực:

- **Hỗ trợ tiếp cận (Accessibility):** Đây là ứng dụng truyền thống và cốt lõi của TTS, được sử dụng trong các trình đọc màn hình (screen readers) giúp người khiếm thị tiếp cận thông tin văn bản trên máy tính và thiết bị di động. Ngoài ra, TTS còn hỗ trợ những người mất khả năng nói (speech impaired) giao tiếp thông qua các thiết bị tạo giọng nói.
- **Tương tác người - máy (Human-Computer Interaction):** TTS đóng vai trò là kênh phản hồi thông tin trong các hệ thống trợ lý ảo (Virtual Assistants), hệ thống nhà thông minh và các thiết bị IoT. Công nghệ này cho phép giao diện người dùng chuyển từ dạng hình ảnh sang dạng giọng nói (Voice User Interface - VUI).
- **Giáo dục và Đào tạo:** Trong lĩnh vực giáo dục, TTS được dùng để hỗ trợ học ngoại ngữ (cung cấp mẫu phát âm chuẩn), hỗ trợ người mắc chứng khó đọc (dyslexia) và tự động hóa việc chuyển đổi tài liệu học tập thành dạng âm thanh (audio learning).
- **Truyền thông và Giải trí:** Công nghệ này được sử dụng để sản xuất sách nói (audiobooks) tự động, đọc tin tức trên các báo điện tử, và lồng tiếng tự động cho các nội dung số (video, trò chơi điện tử), giúp giảm thiểu chi phí và thời gian sản xuất so với thu âm truyền thống.
- **Hệ thống chỉ đường và Giao thông thông minh:** TTS được tích hợp trong các thiết bị định vị GPS và bản đồ số để cung cấp hướng dẫn di chuyển thời gian thực, giúp người lái xe tập trung quan sát mà không cần nhìn màn hình.
- **Dịch vụ công cộng và Viễn thông:** Ứng dụng trong các hệ thống trả lời tự động (IVR) tại các tổng đài chăm sóc khách hàng và hệ thống thông báo công cộng tại nhà ga, sân bay.

3 Các hướng tiếp cận chính

Sự phát triển của bài toán tổng hợp tiếng nói (TTS) đã trải qua những bước chuyển mình mạnh mẽ về mặt kỹ thuật. Dựa trên nguyên lý hoạt động và khả năng tổng quát hóa dữ liệu, các phương pháp tiếp cận có thể được phân chia thành ba cấp độ chính như sau:

3.1 Level 1: Hệ thống dựa trên luật và ghép nối (Rule-based & Concatenative)

Trong giai đoạn đầu của công nghệ tổng hợp tiếng nói, các phương pháp tiếp cận chủ yếu dựa vào việc mô hình hóa thủ công hoặc ghép nối tín hiệu số mà chưa có sự tham gia của các mô hình học sâu. Hai nhánh tiêu biểu nhất ở cấp độ này là Tổng hợp Formant (Formant Synthesis) và Tổng hợp ghép nối (Concatenative Synthesis).

Tổng hợp Formant hoạt động dựa trên việc mô phỏng cơ chế vật lý của đường thanh quản con người. Thay vì sử dụng dữ liệu giọng nói thực, hệ thống tạo ra âm thanh nhân tạo bằng cách điều khiển các tham số âm học như tần số cơ bản (F_0), các tần số cộng hưởng (formants) và mức năng lượng nhiễu. Ưu điểm lớn nhất của phương pháp này là tính ổn định và khả năng kiểm soát tuyệt đối các tham số đầu ra, tuy nhiên, chất lượng âm thanh thường mang tính chất cơ học ("robotic") và thiếu các sắc thái tự nhiên của con người.

Khắc phục nhược điểm về độ tự nhiên, Tổng hợp ghép nối (Concatenative Synthesis) tiếp cận bài toán theo hướng lưu trữ và truy xuất. Hệ thống duy trì một cơ sở dữ liệu khổng lồ chứa các đơn vị âm thanh được ghi âm từ người thật (như từ, âm tiết, hoặc diphones). Trong quá trình tổng hợp, các thuật toán tìm kiếm tối ưu (điển hình là Unit Selection sử dụng thuật toán Viterbi) sẽ lựa chọn và ghép nối các đoạn âm thanh khớp nhất với văn bản đầu vào. Mặc dù phương pháp này tạo ra giọng nói có độ chân thực cao tại từng phân đoạn, nhưng nhược điểm chí mạng nằm ở sự thiếu liên mạch tại các điểm nối (glitch) và sự hạn chế trong việc thay đổi ngữ điệu hay cảm xúc, do hệ thống bị giới hạn bởi những gì đã được ghi âm sẵn trong cơ sở dữ liệu.

3.2 Level 2: Mô hình Deep Learning (Neural TTS)

Sự xuất hiện của Deep Learning vào khoảng năm 2016 đã đánh dấu bước ngoặt chuyển dịch sang các mô hình tham số thống kê sử dụng mạng nơ-ron (Neural Parametric Synthesis). Ở cấp độ này, bài toán TTS thường được giải quyết thông qua một quy trình hai giai đoạn (two-stage pipeline), bao gồm Mô hình âm học (Acoustic Model) và Bộ dựng tiếng (Vocoder).

Trong giai đoạn thứ nhất, Mô hình âm học có nhiệm vụ chuyển đổi chuỗi ký tự văn bản đầu vào thành một biểu diễn trung gian của âm thanh, phổ biến nhất là biểu đồ phổ Mel (Mel-spectrogram). Các kiến trúc mạng nơ-ron tiên tiến như Tacotron (sử dụng RNN/LSTM và cơ chế Attention) hay sau này là FastSpeech (sử dụng Transformer và cơ chế Non-autoregressive) cho phép mô hình học được mối quan hệ phức tạp giữa văn bản và các đặc trưng âm học, bao gồm cả cách ngắt nghỉ và ngữ điệu, vượt xa khả năng của các hệ thống dựa trên luật.

Giai đoạn thứ hai sử dụng một Neural Vocoder để chuyển đổi Mel-spectrogram thành tín hiệu dạng sóng (waveform) có thể nghe được. Sự ra đời của các mô hình sinh mẫu như WaveNet, và sau này là các biến thể nhẹ hơn như HiFi-GAN hay WaveGlow, đã giải quyết được bài toán khôi phục pha và chi tiết tần số cao, tạo ra âm thanh có độ trung thực gần như không thể phân biệt với giọng người thật. Tuy nhiên, hạn chế của cấp độ này là mô hình thường cần lượng dữ liệu lớn của một người nói cụ thể để huấn luyện ("single-speaker dependent") và khả năng thích ứng với giọng mới (voice adaptation) đòi hỏi quá trình tinh chỉnh (fine-tuning) tốn kém.

3.3 Level 3: Few-shot và Voice Cloning (Generative Models)

Cấp độ phát triển hiện đại nhất của TTS tập trung vào khả năng tổng quát hóa (generalization) và học ít mẫu (few-shot learning), coi việc tổng hợp tiếng nói là một bài toán sinh mẫu (generative task) trên quy mô lớn. Mục tiêu là tạo ra hệ thống có thể tổng hợp giọng nói của bất kỳ ai chỉ với một mẫu tham chiếu ngắn (vài giây) mà không cần huấn luyện lại mô hình (Zero-shot TTS).

Các mô hình tại cấp độ này, ví dụ như VALL-E hay Tortoise-TTS, thường áp dụng các kỹ thuật từ mô hình ngôn ngữ lớn (Large Language Models). Chúng sử dụng các bộ mã hóa âm thanh (Audio Codec) để lượng tử hóa tín hiệu giọng nói thành các token rời rạc, sau đó huấn luyện mô hình để dự đoán token âm thanh dựa trên văn bản và token của giọng mẫu. Cách tiếp cận này cho phép hệ thống học được không gian biểu diễn giọng nói (latent speaker space) phong phú từ hàng chục nghìn giờ dữ liệu đa dạng.

Ngoài ra, một hướng tiếp cận khác là sử dụng Mô hình khuếch tán (Diffusion Models), trong đó quá trình tổng hợp được coi là quá trình khử nhiễu (denoising) dần dần từ một phân phối ngẫu nhiên để tạo ra Mel-spectrogram hoặc waveform. Các hệ thống Level 3 không chỉ đạt được khả năng sao chép giọng nói (Voice Cloning) chính xác về mặt âm sắc mà còn bảo toàn được phong cách, cảm xúc và môi trường âm học của giọng mẫu, mở ra tiềm năng ứng dụng to lớn trong việc cá nhân hóa trải nghiệm người dùng.

4 So sánh tổng hợp các hướng tiếp cận

Dựa trên các phân tích kỹ thuật ở trên, Bảng 1 dưới đây tóm tắt các ưu điểm, nhược điểm và phạm vi ứng dụng tối ưu cho từng hướng tiếp cận trong bài toán tổng hợp tiếng nói.

Bảng 1: Bảng so sánh các phương pháp tiếp cận trong bài toán Text-to-Speech

Phương pháp	Ưu điểm	Nhược điểm	Trường hợp nên dùng
Level 1: Rule-based & Concatenative	- Chi phí tính toán cực thấp, chạy tốt trên CPU yếu. - Độ trễ (latency) thấp. - Dễ hiểu (Intelligible) về mặt nội dung.	- Giọng nói thiếu tự nhiên, nghe như máy (robotic). - Khó thay đổi ngữ điệu hoặc cảm xúc. - Gặp lỗi "glitch" tại các điểm nối âm.	Các thiết bị nhúng (embedded) tài nguyên hạn chế, hệ thống thông báo công cộng cố định, môi trường offline không có GPU.
Level 2: Neural TTS (End-to-End)	- Chất lượng âm thanh tự nhiên, tiệm cận người thật. - Ngữ điệu mượt mà, ổn định cao. - Đã được kiểm chứng trong môi trường thương mại.	- Cần lượng dữ liệu lớn để huấn luyện một giọng cụ thể (High resource). - Khó thích ứng nhanh với giọng mới (cần fine-tune). - Yêu cầu phần cứng mạnh (GPU/NPU) để chạy thời gian thực.	Trợ lý ảo thương mại (Siri, Google), sản xuất sách nói (Audiobooks), tổng đài CSKH tự động, các ứng dụng cần chất lượng "studio".
Level 3: Generative TTS (Few-shot/Zero-shot)	- Khả năng Voice Cloning chỉ với mẫu ngắn (3s-10s). - Biểu đạt cảm xúc và phong cách đa dạng. - Tổng quát hóa tốt cho giọng chưa từng gặp (Unseen speakers).	- Tốc độ suy luận chậm, chi phí tính toán rất cao. - Đôi khi kém ổn định (lặp từ, bỏ từ, ảo giác). - Rủi ro về đạo đức và bảo mật (Deepfake).	Cá nhân hóa trải nghiệm người dùng, lồng tiếng phim/game tự động (NPCs), hỗ trợ người mất giọng nói (Voice banking), sáng tạo nội dung linh hoạt.

5 Mọi số hướng nghiên cứu pipeline tối ưu hóa

Bên cạnh việc cải thiện chất lượng âm thanh, các nghiên cứu hiện đại đang tập trung giải quyết các thách thức về hiệu năng triển khai và khả năng biểu đạt phong phú của giọng nói.

5.1 Tối ưu hóa Pipeline và Triển khai (Optimization & Deployment)

Để đưa các mô hình Neural TTS nặng nề (như Tacotron2, VALL-E) lên các thiết bị biên (mobile, IoT) hoặc phục vụ lượng lớn người dùng thời gian thực, các kỹ thuật sau thường được áp dụng:

- Mô hình Non-autoregressive (Song song hóa): Thay thế cơ chế sinh tuần tự (từ trái sang phải) của Tacotron bằng cơ chế sinh song song như FastSpeech 2 hoặc ParaNet. Điều này giúp tăng tốc độ tổng hợp (inference speed) lên gấp hàng chục lần, giảm đáng kể độ trễ (latency).
- Chưng cất tri thức (Knowledge Distillation): Sử dụng một mô hình lớn, chất lượng cao (Teacher) để dạy một mô hình nhỏ gọn hơn (Student). Mô hình Student học cách bắt chước đầu ra của Teacher nhưng với số lượng tham số ít hơn nhiều, giúp giảm dung lượng bộ nhớ và CPU.
- Lượng tử hóa (Quantization): Chuyển đổi trọng số của mô hình từ dạng số thực 32-bit (FP32) xuống 8-bit (INT8). Kỹ thuật này có thể giảm kích thước mô hình xuống 4 lần mà ít làm suy giảm chất lượng âm thanh, phù hợp cho triển khai trên di động.

5.2 Các hướng nghiên cứu tiềm năng

- Expressive TTS (TTS biểu cảm): Nghiên cứu cách kiểm soát các yếu tố siêu ngôn ngữ (paralinguistic) như cảm xúc (vui, buồn, giận dữ), cường độ và nhịp điệu. Mục tiêu là giúp người dùng có thể điều chỉnh giọng nói đầu ra một cách chi tiết (ví dụ: "đọc câu này với giọng thì thầm và buồn bã").
- Cross-lingual & Code-switching TTS: Phát triển các mô hình có khả năng nói đa ngôn ngữ mượt mà trong cùng một câu (ví dụ: tiếng Việt pha tiếng Anh) mà vẫn giữ được chất giọng của một người nói duy nhất. Đây là bài toán rất quan trọng đối với các ngôn ngữ châu Á.
- TTS bền vững: Tăng cường khả năng chịu lỗi của mô hình khi dữ liệu đầu vào (văn bản hoặc giọng mẫu) bị nhiễu. Điều này đặc biệt quan trọng đối với bài toán Zero-shot voice cloning khi giọng mẫu tham chiếu có chất lượng thấp hoặc lẫn tiếng ồn môi trường.

6 Kết luận

Bài toán Text-to-Speech đã trải qua một hành trình phát triển dài, từ những âm thanh nhân tạo máy móc của phương pháp Formant đến những giọng nói tự nhiên đầy cảm xúc của kỷ nguyên Generative AI.

Thông qua việc phân tích các hướng tiếp cận, báo cáo đã chỉ ra sự chuyển dịch xu hướng từ các hệ thống dựa trên luật (Rule-based) sang các mô hình học sâu (Deep Learning) và gần đây là các mô hình sinh mẫu lớn (Large Generative Models). Trong khi các phương pháp truyền thống vẫn giữ ưu thế về tốc độ và sự đơn giản, các mô hình Neural TTS (End-to-End) đã thiết lập những chuẩn mực mới về độ tự nhiên và khả năng hiểu ngữ cảnh. Đặc biệt, sự nổi lên của các kỹ thuật Few-shot và Zero-shot Learning đang mở ra kỷ nguyên cá nhân hóa giọng nói, nơi rào cản về dữ liệu thu âm dần bị xóa bỏ.

Tuy nhiên, thách thức vẫn còn đó trong việc cân bằng giữa chất lượng âm thanh, tốc độ suy luận thời gian thực và đạo đức sử dụng AI (ngăn chặn Deepfake). Các nghiên cứu trong tương lai hứa hẹn sẽ không chỉ tập trung vào việc làm cho máy nói "giống người" hơn, mà còn làm cho hệ thống trở nên nhẹ hơn, linh hoạt hơn và đa ngôn ngữ hơn, đưa giao diện giọng nói trở thành phương thức tương tác chủ đạo trong thế giới số.

bibappendix

7 Tài liệu tham khảo

[heading=bibappendix]